NFE106 – Administration de bases de données
Examen 1er juillet 2021 – session 1 – 3h (4 pages)

Consignes : cet examen est exceptionnellement organisé à distance. Vous devez rendre votre copie numérisée à 21h00 au plus tard. Aucune copie ne sera acceptée après cette heure limite. Les seuls formats acceptés sont le PDF et le JPEG, ceci afin d'éviter tout problème de lecture. Prenez vos dispositions pour être en mesure de fournir le bon format le moment venu. Une activité de discussion en direct (« *chat* ») est ouverte dans l'espace Moodle pour d'éventuelles questions.

1 Stockage et indexation (7 pts)

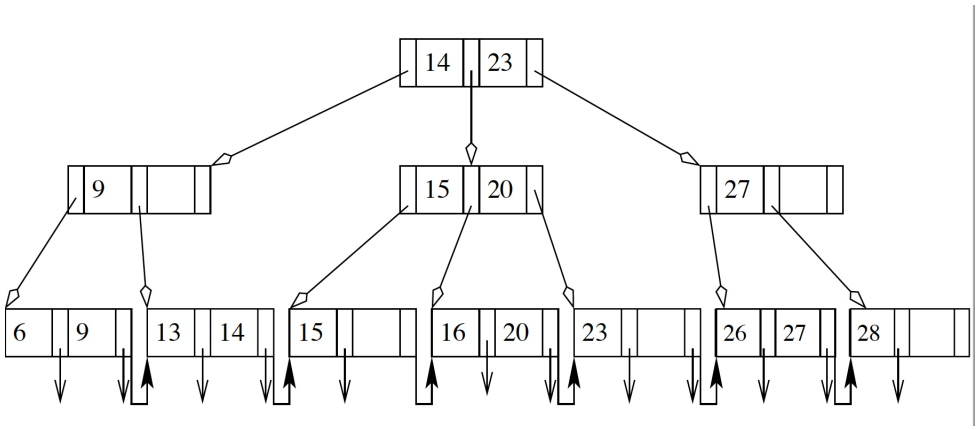

FIGURE 1 – Un arbre B

1. Une table relationnelle contient 256 500 lignes. On la stocke dans une base avec des blocs de 4 000 octets. On suppose que chaque enregistrement a une taille de 200 octets et que chaque bloc a un entête de 100 octets. Quel est le nombre d'enregistrements par bloc ? Quel est le nombre de blocs nécessaire pour stocker la table (on suppose que les blocs contiennent autant d'enregistrements que possible) ?
2. Expliquez la différence entre un index dense et un index non-dense. Combien d'index denses peut-on construire sur un fichier ? Combien d'index non-denses ?
3. La figure 1 montre un arbre B. On peut stocker au plus 2 entrées par bloc. Indiquez le rôle des différents pointeurs représentés, et donnez l'arbre après insertion d'un enregistrement de clé 17 (dessinez au moins les parties de l'arbre qui ont changé).
4. On effectue une recherche sur l'intervalle [13,23] (avant l'insertion de la clé 17). Combien de blocs lit-on dans l'index, et combien de blocs *au pire* doit-on lire dans le fichier ?
5. On indexe une table par un arbre B sur un identifiant dont les valeurs sont fournies par une *séquence*. À chaque insertion un compteur est incrémenté et fournit la valeur de clé de l'enregistrement inséré.

   On suppose qu'il n'y a que des insertions dans la table. Montrez que tous les nœuds de l'index qui ont un frère droit sont exactement à moitié pleins.

Correction

1. On place 19 enregistrements par bloc. Il faut $\lceil \frac{256\,500}{19} \rceil = 13\,500$ blocs.
2. Index dense et non dense : voir le cours
3. Structure d'un arbre B+ : voir le cours
4. Au moment d'un éclatement, on se retrouve avec deux blocs remplis à moitié. Celui qui a un frère droit ne contient que valeurs de clés inférieures à celui de son frère droit. Comme on n'insère que des valeurs supérieures à toutes celles existantes, un nœud qui a un frère droit ne sera jamais modifié.

2 Optimisation (9 points)

Soit les tables relationnelles suivantes (les attributs qui forment une clé sont en gras) :
— Produit (**code**, nom, marque, prix)
— Client (**id**, nom, prénom)
— Achat (**codeProduit**, **idClient**, date, quantité)
On donne ci-dessous une requête SQL et le plan d'exécution fourni par Oracle :

```
select quantité
from Produit as p, Client as c, Achat as a
where p.code = a.codeProduit
and   c.id = a.idClient
and   prix > 50
```

Plan d'exécution :

```
0 SELECT STATEMENT
  1 MERGE JOIN
    2 SORT JOIN
      3 NESTED LOOPS
        4 TABLE ACCESS FULL ACHAT
        5 TABLE ACCESS BY INDEX ROWID PRODUIT
          6 INDEX UNIQUE SCAN A34561
    7 SORT JOIN
      8 TABLE ACCESS FULL Client
```

1. Que peut-on déduire de ce plan : peut-on savoir s'il existe un index sur la table Client ? Sur la table Produit ? Sur la table Achat ? Si vous pensez qu'un index existe, donnez les attributs indexés. Justifiez vos réponses.

Correction
Il existe un index sur l'attribut code de la table Produit; en revanche pas d'index sur l'id de la table Client, sinon on n'aurait pas besoin d'un tri-fusion. Tout ce qu'on peut dire sur la table Achat, c'est qu'il n'y a pas d'index dont l'id du client soit un préfixe (sinon on pourrait parcourir séquentiellement Client et accéder aux autres tables par l'index).

2. Quels sont les algorithmes de jointure utilisés ? Expliquer le fonctionnement de ce plan d'exécution.

Correction

Un algo. de boucles imbriquées indexées sur Achat-Produit, un algo de sort/merge sur le résultat de cette jointure et la table Client.

3. Quel(s) index peut-on ajouter pour obtenir les meilleures performances possibles ? Donnez, sous la forme que vous souhaitez, le plan d'exécution après ajout d'index.

Correction

Solution : on peut ajouter un index sur l'id de client, et sur le prix du produit. Dans ce cas le plan est :

```
Plan d'execution
----------------------------------------------------------------------------
0 SELECT STATEMENT
  1 NESTED LOOPS
    2 NESTED LOOPS
      3 TABLE ACCESS BY INDEX ROWID PRODUIT
        4 INDEX RANGE SCAN PRODUIT_PRIX
      5 TABLE ACCESS BY INDEX ROWID ACHAT
        6 INDEX UNIQUE SCAN ACHAT_CODEPRODUIT
    7 TABLE ACCESS BY INDEX ROWID CLIENT
      8 INDEX RANGE SCAN CLIENT_ID
```

4. On fait une jointure entre les tables Produit et Achat. Produit occupe 500 blocs, Achat 10 000 blocs. Vaut-il mieux appliquer un algorithme de boucles imbriquées ou de hachage si la mémoire M disponibe est de 600 blocs ?
5. Même question si la mémoire est de 101 blocs ? Indiquez dans chaque cas le nombre d'entrées/sorties (sans prendre en compte l'écriture du résultat final).

   Pour ces deux questions : expliquez le fonctionnement respectif des boucles imbriquées et de la jointure par hachage.

Correction

$M = 600$: on lit Produit en mémoire, et une lecture de Achat suffit, dont coût égal à 10 500 blocs pour les boucles imbriquées. Avec le hachage : on hache Produit (coût = 1 000 blocs) et Achat (coût = 20 000 blocs). On relit les deux. Coût total : 31 500 blocs.

$M = 100$: avec les boucles imbriquées on doit lire 1 fois Produit et 5 fois Achat, pour un coût de 50 500 blocs. Sinon on hache les deux (coût= 21 000 blocs) et on les relit une fois (coût total 31 500 blocs).

3 Concurrence (4 points)

Soit l'exécution concurrente suivante :

$$H = r_2[y]w_1[x]r_1[x]r_3[z]w_2[z]w_3[x]c_1w_3[z]c_3r_2[x]c_2$$

1. Donner la liste des conflits de H. (0,5 point)

Correction

Conflits :

1. En x : w_1w_3, w_1r_2, r_1w_3, et w_3r_2
2. En y : -
3. En z : r_3w_2, w_2w_3

2. Donner le graphe de sérialisabilité de H. Que pouvez-vous déduire de ce graphe ? (0,5 point)

Correction

Les arêtes : $T_1 \rightarrow T_3$; $T_1 \rightarrow T_2$; $T_3 \rightarrow T_2$; $T_3 \rightarrow T_2$ et $T_2 \rightarrow T_3$.

Il y a un cycle donc l'exécution n'est pas sérialisable.

3. Donner l'exécution obtenue par application de l'algorithme de verrouillage à deux phases. Détailler le déroulement de l'algorithme. (2 points)

Correction

La lecture $w_2[z]$ est bloquée par $r_3[z]$. T_2 est mise en attente et T_3 termine. T_2 est alors débloquée et termine.

$$H_{finale} = r_2[y]w_1[x]r_1[x]r_3[z]c_1w_3[x]w_3[z]c_3w_2[z]r_2[x]c_2$$